



Univerzitet u Beogradu
Matematički fakultet

Seminarski rad

WAKE WORD DETECTION

Mentor:

Stefan Kapunac

Katedra za računarstvo i informatiku

Studenti:

Iva Milutinović 262/2021

Jovana Medenica 364/2022

Smer: Informatika

Datum: 2025/26

Sadržaj

1	Uvod	2
2	Opis rešenja	4
2.1	Skup podataka	4
2.2	Pretprocesiranje audio signala	5
2.3	MFCC reprezentacija	6
2.4	LFCC reprezentacija	8
2.5	CNN arhitektura	11
2.6	Treniranje modela	13
3	Eksperimentalni rezultati	17
3.1	Rezultati MFCC modela	17
3.2	Rezultati LFCC modela	20
3.3	Poređenje MFCC i LFCC pristupa	23
4	Zaključak	26
5	Literatura	27

1 Uvod

Wake word detection predstavlja problem automatskog prepoznavanja unapred definisane ključne reči ili fraze u audio signalu. Ovakvi sistemi danas imaju veoma široku primenu u savremenim glasovno kontrolisanim uređajima i digitalnim asistentima kao što su Amazon Alexa, Apple Siri i Google Assistant. Njihov osnovni zadatak jeste da kontinuirano analiziraju audio signal i aktiviraju sistem tek nakon detekcije određene ključne reči, čime se omogućava prirodnija i jednostavnija interakcija između čoveka i računara.

Razvoj pouzdanih wake word sistema predstavlja izazovan problem iz oblasti obrade govora i mašinskog učenja. Audio signali mogu sadržati šum, različite akcente, varijacije u brzini govora i različite karakteristike glasa govornika. Pored toga, sistemi za detekciju ključnih reči moraju biti dovoljno precizni da izbegnu lažne aktivacije, ali i dovoljno osetljivi da ne propuste stvarno izgovorenu aktivacionu reč. Zbog toga je izbor odgovarajuće reprezentacije audio signala od velikog značaja za uspešnost sistema.

U sistemima za automatsku obradu govora audio signal se najčešće ne koristi direktno kao ulaz u model mašinskog učenja. Umesto toga, iz audio signala se izdvajaju karakteristične osobine (engl. *features*) koje predstavljaju kompaktniji i informativniji opis govora. Među najpoznatijim metodama za izdvajanje osobina nalaze se Mel-Frequency Cepstral Coefficients (MFCC) i Linear Frequency Cepstral Coefficients (LFCC). MFCC koristi Mel skalu frekvencija koja aproksimira način na koji čovek percipira zvuk, dok LFCC koristi linearno raspoređene frekvencijske filtere i ravnomernije predstavlja čitav frekvencijski opseg audio signala.

U poslednjih nekoliko godina konvolucione neuronske mreže (*Convolutional Neural Networks – CNN*) pokazale su veoma dobre rezultate u zadacima klasifikacije audio signala i prepoznavanja govora. Razlog tome je činjenica da se reprezentacije poput MFCC i LFCC mogu posmatrati kao dvodimenzionalne matrice slične slikama, što omogućava efikasnu primenu konvolucionih slojeva za prepoznavanje karakterističnih obrazaca u vremensko-frekvencijskom domenu.

U ovom radu razmatra se problem detekcije ključne reči “stop” korišćenjem konvolucionih neuronskih mreža. Kao skup podataka korišćen je Google Speech Commands dataset, koji sadrži veliki broj kratkih audio snimaka različitih izgovorenih reči. Poseban fokus rada stavljen je na poređenje dve metode za izdvajanje osobina audio signala – MFCC i LFCC reprezentacija.

Cilj rada nije razvoj nove arhitekture neuronske mreže, već analiza uticaja različitih audio reprezentacija na performanse sistema za wake word detekciju.

U eksperimentalnom delu rada implementirano je dva CNN modela koji su trenirani odvojeno nad MFCC i LFCC reprezentacijama audio signala. Dobi-jeni rezultati analizirani su korišćenjem standardnih metrika za klasifikaciju kao što su accuracy, precision, recall i F1-score, sa ciljem određivanja pogod-nije reprezentacije za zadatak detekcije ključne reči.

2 Opis rešenja

2.1 Skup podataka

Za potrebe razvoja i testiranja sistema za detekciju ključne reči korišćen je Google Speech Commands dataset. Ovaj skup podataka predstavlja jedan od najčešće korišćenih skupova podataka u zadacima prepoznavanja govora i klasifikacije kratkih audio komandi. Dataset sadrži veliki broj audio snimaka različitih reči izgovorenih od strane velikog broja govornika različitog pola, uzrasta i akcenata.


Audio snimci u dataset-u sačuvani su u `.wav` formatu, pri čemu svaki snimak traje približno jednu sekundu. Uzorci su snimani sa frekvencijom od 16 kHz i predstavljaju kratke govorne komande poput *stop*, *go*, *left*, *right*, *yes*, *no* i druge.

U okviru ovog rada kao aktivaciona reč (*wake word*) odabrana je reč “*stop*”. Problem je formulisan kao zadatak binarne klasifikacije:

- pozitivna klasa predstavlja audio snimke reči “*stop*”,
- negativna klasa obuhvata sve ostale reči iz dataset-a.

Na ovaj način model uči da razlikuje ciljnu ključnu reč od ostalih govornih komandi. Za svaki audio snimak vršeno je izdvajanje karakterističnih osobina audio signala korišćenjem MFCC i LFCC reprezentacija, koje su zatim korišćene kao ulaz u konvolucionu neuronsku mrežu.

Na slici 1 prikazan je primer audio signala reči “*stop*” iz korišćenog skupa podataka.



Slika 1: Prikaz audio signala reči “stop” iz Google Speech Commands dataset-a

2.2 Pretprocesiranje audio signala

Pre izdvajanja karakterističnih osobina audio signala bilo je potrebno izvršiti pretprocesiranje audio podataka kako bi svi ulazni primeri imali uniforman format pogodan za obradu neuronskom mrežom. Pretprocesiranje predstavlja važan korak u sistemima za obradu govora, jer omogućava stabilnije i efikasnije treniranje modela.


Audio snimci iz Google Speech Commands dataset-a učitavani su korišćenjem biblioteke **Librosa**. Svi audio fajlovi konvertovani su na frekvenciju od 16 kHz, što predstavlja standardnu frekvenciju uzorkovanja u zadacima prepoznavanja govora. Nakon učitavanja audio signal je podeljen na manje vremenske segmente korišćenjem Short-Time Fourier Transform (STFT) metode, čime je omogućena analiza frekvencijskih karakteristika zvuka kroz vreme.

Nakon transformacije audio signala u vremensko-frekvencijski domen vršeno je izdvajanje karakterističnih osobina korišćenjem MFCC i LFCC reprezentacija. Ove reprezentacije omogućavaju kompaktniji opis audio signala i isticanje informacija relevantnih za razlikovanje govornih komandi.

Dobijene MFCC i LFCC matrice nisu imale identične dimenzije za sve audio snimke, zbog čega je bilo potrebno izvršiti usklađivanje dimenzija. U okviru implementacije korišćen je postupak *padding/truncation*, pri čemu su kraće matrice dopunjavane nulama, dok su duže matrice skraćivane na unapred definisanu maksimalnu dužinu. Na taj način svi ulazni primeri dobili su jedinstvenu dimenziju pogodnu za ulaz u konvolucionu neuronsku mrežu.

Nakon formiranja konačnog skupa podataka izvršena je podjela na trening i test skup korišćenjem funkcije `train_test_split` iz biblioteke `Scikit-learn`. Za treniranje modela korišćeno je 75% podataka, dok je preostalih 25% korišćeno za evaluaciju uspešnosti modela. Podjela je izvršena uz očuvanje odnosa klasa korišćenjem *stratified split* pristupa.

Kompletan postupak pretprocesiranja audio signala prikazan je na slici 2.



Slika 2: Pipeline sistema za wake word detekciju


2.3 MFCC reprezentacija

MFCC (Mel-Frequency Cepstral Coefficients) je jedna od najčešće korišćenih metoda za izdvajanje karakteristika iz audio signala i najčešće se koristi upravo u prepoznavanju govora te je idealan kandidat za obradu skupa podataka u našem projektu. Cilj MFCC reprezentacije je da iz sirovog audio signala izdvoji informacije koje najbolje opisuju ljudski govor na osnovu toga kako ljudsko uho precepcira zvuk.

Sam proces dobijanja MFCC koeficijenata se sastoji iz nekoliko koraka.

- Windowing,
- STFT,
- Spectrogram,
- Mel-frequency filtering,
- LOG,

- DCT,
- MFCC.



Slika 3: MFCC pipeline

Prvi korak je windowing, tada se audio signal deli na male vremenske segmente, najčešće od 20 do 40 ms. To se radi zato što govor sam po sebi nije stabilan tokom celog audio snimka, ali jeste približno stabilan u veoma kratkim intervalima pa se svaki vremenski segment može pojedinačno analizirati.

Sledeći korak je STFT (Short-Time Fourier Transform) odnosno za svaki frejm se radi Furijerova transformacija. Time se signal iz vremenskog domena pretvara u frekvencijski domen. Na ovaj način saznajemo koje frekvencije postoje u tom delu govora i kolika je njihova energija. Rezultat ovog koraka je spektar frekvencija za svaki mali segment zvuka.


Kada smo izvršili Furijerovu transformaciju za svaki segment, možemo spojiti rezultate svih frejmova i tako dobijamo spektrogram. Spektrogram je 2D prikaz koji izgleda kao slika i pogodan je za korišćenje od strane CNN modela. X-osa prikazuje vreme, y-osa prikazuje frekvenciju, a boja odnosno intenzitet označava jačinu energije.

Iako CNN modeli mogu da koriste spektrograme MFCC ide korak dalje i dodatno prilagođava podatke ljudskom sluhu. To radi tako što primenjuje Mel filtere, tj. dobijeni spektar prolazi kroz skup filtera raspoređenih po Mel skali. Mel skala pokušava da imitira ljudsko uho odnosno mnogo bolje razlikuje niske frekvencije od visokih. Zato filteri gušće pokrivaju niske frekvencije, a ređe visoke. Rezultat je da signal postaje prilagođen percepciji govora i ovim procesom se uklanja deo nepotrebnih informacija.


Ljudsko uho ne doživljava glasnoću linearno pa se na energije Mel filtera primenjuje logaritamska funkcija kako bi se smanjile razlike u energiji, stabilizovali podaci i poboljšao rad modela.

Na samom kraju radi se diskretna kosinusna transformacija (DTC). Njena

uloga je da ukloni redundantne informacije, kompresuje podatke i izdvoji najvažnije karakteristike govora i tako se dobijaju konačni MFCC koeficijenti. Finalni rezultat je MFCC matrica koja se često tretira kao slika nad kojom se rade konvolucije. MFCC matrica se koristi kao ulaz za CNN.



Slika 4: Spektrogram



Slika 5: MFCC matrica za audio signal reči stop

2.4 LFCC reprezentacija

Linear Frequency Cepstral Coefficients (LFCC) predstavljaju jednu od metoda za izdvajanje karakterističnih osobina audio signala koja se često koristi u zadacima obrade govora i audio klasifikacije. LFCC reprezentacija omogućava


transformaciju audio signala iz vremenskog domena u kompaktnu vremensko-frekvencijsku reprezentaciju pogodnu za obradu metodama mašinskog učenja.

Za razliku od MFCC reprezentacije, koja koristi Mel skalu frekvencija zasnovanu na načinu na koji čovek percipira zvuk, LFCC koristi linearno raspoređene frekvencijske filtere. Na ovaj način čitav frekvencijski opseg audio signala tretira se ravnomerno, bez dodatnog naglašavanja nižih frekvencija. Zbog toga LFCC reprezentacija može sačuvati više informacija o višim frekvencijama audio signala.

Proces izdvajanja LFCC karakteristika započinje podelom audio signala na manje vremenske segmente. Nakon toga nad svakim segmentom primenjuje se Short-Time Fourier Transform (STFT), čime se audio signal transformiše iz vremenskog u frekvencijski domen. Dobijeni spektrogram zatim prolazi kroz skup linearno raspoređenih frekvencijskih filtera (*linear filter bank*), koji mere energiju signala u različitim frekvencijskim opsezima.

Nakon filtriranja primenjuje se logaritamska transformacija radi smanjenja dinamičkog opsega vrednosti i stabilizacije reprezentacije audio signala. Na kraju se primenjuje Discrete Cosine Transform (DCT), čime se dobijaju cepstralni koeficijenti koji predstavljaju konačnu LFCC reprezentaciju audio signala.

Kompletan postupak izdvajanja LFCC karakteristika prikazan je na slici 6.



Slika 6: Postupak izdvajanja LFCC karakteristika


LFCC matrica predstavlja vremensko-frekvencijsku reprezentaciju audio signala, pri čemu redovi matrice predstavljaju cepstralne koeficijente, dok kolone predstavljaju vremenske segmente audio signala. Na ovaj način moguće je analizirati promene frekvencijskih karakteristika govora kroz vreme.

U okviru implementacije za svaki vremenski segment audio signala računato je 13 LFCC koeficijenata. Audio signal je podeljen na 32 vremenska segmenta, zbog čega konačna LFCC reprezentacija ima dimenzije 13×32 . Kako bi svi ulazni primeri imali iste dimenzije pogodne za obradu konvolucionom neuronskom mrežom, primenjen je postupak dopunjavanja ili skraćivanja matrica (*padding/truncation*).

Primer LFCC matrice za audio signal reči “stop” prikazan je na slici 7.

Sa slike 7 može se uočiti vremensko-frekvencijska reprezentacija audio signala reči “stop” dobijena korišćenjem LFCC metode. Horizontalna osa predstavlja vremenske segmente audio signala, dok vertikalna osa predstavlja LFCC koeficijente.

Različite boje u matrici predstavljaju različite vrednosti energije u određenim frekvencijskim opsezima. Svetlije oblasti označavaju veće vrednosti koeficijenata, dok tamnije oblasti predstavljaju manje vrednosti energije signala.



Slika 7: LFCC matrica za audio signal reči “stop”

Može se primetiti da se tokom izgovora reči “stop” određeni LFCC koeficijenti značajno menjaju kroz vreme, što ukazuje na promenu frekvencijskih karakteristika govora. Posebno su izražene promene u nižim koeficijentima, koji sadrže najvažnije informacije o spektralnoj strukturi audio signala.

LFCC matrica predstavlja kompaktan opis audio signala i omogućava konvolucionu neuronskoj mreži da efikasno prepozna karakteristične obrasce povezane sa izgovorom ključne reči.

2.5 CNN arhitektura

Za klasifikaciju audio signala i detekciju ključne reči korišćena je konvoluciona neuronska mreža (Convolutional Neural Network – CNN). Konvolucione neuronske mreže pokazale su veoma dobre rezultate u zadacima klasifikacije slika, obrade zvuka i prepoznavanja govora zbog sposobnosti automatskog izdvajanja karakterističnih obrazaca iz ulaznih podataka.

Klasa WakeWordCNNUnified je upravo naša konvolutivna neuronska mreža. Ova mreža služi za klasifikaciju gde su ulazni parametri MFCC ili LFCC reprezentacije skupa podataka, a izlaz je verovatnoća da audio sadrži aktivacionu reč. MFCC/LFCC matrice su praktično 2D matrice gde jedna osa predstavlja vreme, a druga osa predstavlja frekvencijske koeficijente.

Model ima dva glavna dela u svojoj strukturi: features i classifier.

Features blok služi da automatski pronađe obrasce u MFCC i LFCC ma-

pama, izvuče korisne karakteristike i smanji dimenzije podataka. Sequential znači da se slojevi izvršavaju redom i da je izlaz jednog sloja ulaz u sledeći sloj. Mreža se sastoji od 3 konvoluciona sloja što pomaže mreži da razume kompleksnije obrasce. Pored konvolucionih slojeva koriste se i batch normalizacija, ReLU aktivacija, pooling, global average pooling, potpuno nezavisni slojevi, flatten, dropout i izlaznog sloja.

Prvi konvolucionni sloj ima jedan ulazni kanal i mreža uči 16 različitih filtera dimenzija 3×3 i dodaje se padding kako bi dimenzije ostale iste.

BatchNorm normalizuje izlaz konvolucije i tako pomaže stabilnijem učenju i bržem treningu. Drugi konvolucionni sloj ima 16 feature mapa kao ulaz i izlaz postaje 32 feature mape. Ovo je dublji sloj i on uči kompleksnije obrasce. Za razliku od prvog sloja koji možda prepoznaje ivice i jednostavne frekvencijske promene drugi sloj prepoznaje složenije govorne obrasce, delove fonema i karakteristične strukture aktivacione reči.

Pooling sloj služi da smanji dimenzije feature mapa, time se smanjuje broj podataka, ubrzava trening i zadržavaju se najvažnije informacije. CNN bira maksimalnu vrednost iz malog regiona, što ustvari znači da se zadržavaju najjače karakteristike. Zatim se koristi ReLU aktivacija, to je funkcija $\max(0, x)$, odnosno ako je broj negativan on postaje 0, a ako je pozitivan ostaje isti. ReLU uvodi nelinearnost i bez nje bi cela mreža bila samo linearna transformacija i ne bi mogla da uči složene obrasce.

Adaptive Average Pooling pretvara svaku feature mapu u jednu vrednost i on zapravo smanjuje broj parametara, smanjuje overfitting i omogućava mreži da uzme prosečnu aktivaciju cele feature mape. Često je dosta efikasniji nego veliki potpuno povezani slojevi.

Classifier blok koristi izvučene feature i donosi konačnu odluku. Najpre se koristi flatten kako bi se transformisao format podataka jer linearni slojevi rade sa vektorima. Linearni slojevi predstavljaju potpuno povezane neuronske slojeve u kojima je svaki neuron povezan sa svim neuronima prethodnog sloja. Zatim se pravi linearni sloj koji kombinuje sve naučene feature. On spaja sve informacije iz različitih filtera i odlučuje šta je bitno za aktivacionu reč. Ponovo se koristi ReLU aktivaciona funkcija da bi se uvela nelinearnost, a potom se radi dropout funkcija koja tokom treniranja nasumično ugasi 30% neurona. To sprečava overfitting tj. kako model ne bi zapamtio trening podatke nego naučio generalne obrasce i veoma je korisno kod klasifikacije audio snimaka. Na kraju imamo i poslednji linear sloj čiji je izlaz jedan broj

koji se naziva i logit. Logit može biti bilo koji realan broj, a tek kasnije se koristi aktivaciona funkcija sigmoid kako bi ove vrednosti ubacila u vrednosti u intervalu od 0 do 1 koje bi predstavljale verovatnoću da je u pitanju aktivaciona reč.

2.6 Treniranje modela

Koristeći novonastale MFCC matrice formirali smo dva skupa podataka, jedan za trening i jedan za testiranje tako što smo ceo skup podataka stratifikovano podelili na ova dva skupa. Za te namene smo koristili funkciju `train_test_split` iz biblioteke `Scikit-learn`. Odnos veličina ovih skupova bila je 75 prema 25 procenata za trening odnosno test skup podataka.

Pre samog procesa treniranja modela skupovi podataka su transformisani u PyTorch tensore kako bi bili prikladni za ulaz u konvolutivnu neuronsku mrežu. Takođe dodata je još jedna dimenzija za broj kanala zato što CNN očekuje takav oblik ulaza sa 4 dimenzije. Koristi se float32 tip podataka jer BCEWithLogitsLoss očekuje decimalne vrednosti. TensorDataset spaja ulaze i njihove labele u jedan skup podataka, a DataLoader deli podatke u manje grupe (batch). Tako se obezbeđuje da model ne trenira nad svim podacima odjednom nego uzima onoliko uzoraka koliki je batch, računa grešku, ažurira težine pa tek onda prelazi na sledeći batch. Time se štedi memorija, ubrzava trening i stabilizuje učenje. Shuffle je uključen kako bi sprečio da model nauči redosled podataka.


Kako je naš skup podataka nebalansiran neopodno je da damo nekako prioritet i to rešavamo tako što dodajemo pozitivnoj klasi veću težinu i samim tim obezbeđujemo da su greške nad pozitivnim klasama važnije.

Kako postoji samo dve klase onda koristimo Binary Cross Entropy za binarnu klasifikaciju. BCEWithLogitsLoss interno koristi sigmoid aktivacionu funkciju koja logite pretvara u podatke u opsegu od 0 do 1 koji predstavljaju verovatnoću da su aktivaciona reč. Ova loss funkcija je numerički stabilnija i podržava dodavanje važnosti, odnosno težine određenoj klasi.

Optimizator Adam ažurira težine mreže. Adam dobro radi za CNN modele i automatski prilagođava learning rate. Learning rate određuje veličinu koraka pri učenju i često je teško pronaći idealan korak jer ukoliko je prevelik trening može biti nestabilan, a ukoliko je premali onda trening može biti veoma spor.

Treniranje modela se odvija u epohama gde jedna epoha znači da je model video ceo trening skup jednom, a 10 epoha znači da ceo skup podataka prolazi 10 puta kroz mrežu. Unutar treninga se čuva ukupna greška u toku epohe tako što se porede predikcije modela i stvarne labele i zatim se sabiraju. Radi se backpropagation i računaju se gradijenti, a pre toga je neophodno da se obrišu prethodni gradijenti zato što bi ih PyTorch inače sabirao. Model tako saznaje kako treba da promeni težine da bi smanjio grešku i na samom kraju se radi ažuriranje težina pomoću Adam optimizatora.

Stabilnost treniranja modela možemo videti na osnovu količine greški koje se akumuliraju za svaku epohu. Ukoliko ukupna greška opada to znači da naš model uči kako treba, ipak ukoliko oscilira ukupna greška to znači da je model nestabilan i da treba da ga promenimo.



Slika 8: Promena vrednosti funkcije gubitka tokom treniranja MFCC modela

Sa slike možemo da primetimo da ukupna greška opada, ali i u par trenutaka malo poraste. To nije neuobičajeno kod MFCC reprezentacije podataka i konkretno naše implementacije CNN zbog BatchNorm i Dropout-a pa može da se desi da nekad kombinacija toga napravi kratku oscilaciju i to ne treba da nas zabrinjava jer se vidi da loss opada sve vreme i to znači da naš model uči normalno.

Nakon formiranja LFCC reprezentacija i definisanja arhitekture konvolucione neuronske mreže izvršeno je treniranje modela za zadatak detekcije ključne


reči. Skup podataka podeljen je na trening i test skup korišćenjem funkcije `train_test_split` iz biblioteke `Scikit-learn`. Za treniranje modela korišćeno je 75% podataka, dok je preostalih 25% korišćeno za evaluaciju uspešnosti modela. Podela podataka izvršena je korišćenjem stratifikovanog pristupa kako bi odnos pozitivne i negativne klase bio očuvan u oba skupa.

Pre početka treniranja podaci su konvertovani u PyTorch tenzore i prilagođeni formatu pogodnom za ulaz u konvolucionu neuronsku mrežu. LFCC matrice proširene su dodatnom dimenzijom kanala kako bi odgovarale očekivanom formatu ulaza oblika $batch_size \times channels \times height \times width$.

Za treniranje modela korišćena je Binary Cross-Entropy (BCE) funkcija gubitka identično kao i kod MFCC, koja je pogodna za probleme binarne klasifikacije. Kao optimizator korišćen je Adam optimizator sa stopom učenja od 0.001. Treniranje modela vršeno je u mini-batchevima veličine 32 uzorka tokom 20 epoha.

Tokom procesa treniranja za svaki batch vršeno je prosleđivanje podataka kroz mrežu (*forward propagation*), računanje funkcije gubitka, a zatim ažuriranje parametara mreže korišćenjem postupka propagacije greške unazad (*backpropagation*). Nakon svake epohe računata je prosečna vrednost funkcije gubitka kako bi se pratio napredak modela tokom treniranja.

Implementacija modela realizovana je korišćenjem Python programskog jezika i PyTorch biblioteke za razvoj neuronskih mreža.



Slika 9: Promena vrednosti funkcije gubitka tokom treniranja LFCC modela


Sa slike 9 može se primetiti da vrednost funkcije gubitka značajno opada tokom prvih nekoliko epoha treniranja, nakon čega se smanjenje nastavlja sporijim tempom. Ovakvo ponašanje ukazuje da model uspešno uči karakteristike prisutne u LFCC reprezentacijama audio signala. Iako se u kasnijim epohama mogu primetiti manje oscilacije vrednosti funkcije gubitka, ukupan trend ostaje opadajući, što ukazuje na stabilan proces treniranja i postepeno približavanje modela optimalnom rešenju.

3 Eksperimentalni rezultati

3.1 Rezultati MFCC modela

Nakon treniranja CNN modela nad MFCC reprezentacijama izvršena je evaluacija uspešnosti modela na test skupu podataka. Koršćene su ugrađene funkcije za evaluaciju poput classification report, matrice konfuzije, ROC-AUC krive, PR krive. Za klasifikaciju korišćen je prag odlučivanja od 0.96.

Na sledećoj slici možemo primetiti rezultat funkcije classification report. Primećujemo da je metrika accuracy jako dobra, odnosno iznosi 99%, što bi inače bio jako dobar rezultat, ali u našoj situaciji to nije odgovarajuća metrika za analizu jer je skup podataka nebalansiran. Bolje metrike za procenu kvaliteta modela biće precision, recall i f1-score. Vidimo da su sve tri metrike dale jako dobre rezultate što znači da naš model veoma dobro procenjuje da li je u audio snimku izgovorena aktivaciona reč ili ne i ne dolazi do overfitting-a.




```
MFCC Accuracy: 0.9945000617970584
[[15575   12]
 [   77  518]]
      precision    recall  f1-score   support

      0.0         1.00      1.00      1.00     15587
      1.0         0.98      0.87      0.92        595

 accuracy          0.99          0.99          0.99     16182
 macro avg          0.99          0.93          0.96     16182
 weighted avg          0.99          0.99          0.99     16182
```

Slika 10: Classification report za MFCC model


Pored ovih metrika veoma značajna metrika je i matrica konfuzije od koje zapravo i nastaju prethodne metrike.



Slika 11: Matrica konfuzije za MFCC model


Na slici vidimo da model veoma dobro razdvaja pozitivnu i negativnu klasu, ali takode ima i određen broj propusta najčešće kada je u pitanju pozitivna klasa, a model je predvideo negativnu klasu. Ova brojka nije zabrinjavajuća, ali ju je moguće popraviti pomoću modifikacije praga odlučivanja ili primenom oversampling-a na pozitivnu klasu tokom treninga kako bi se skup podataka izbalansirao.

Još dve metrike korišćene za analizu kvaliteta modela su ROC-AUC kriva i PR kriva.



Slika 12: ROC-AUC kriva za MFCC model

Kod ROC-AUC krive vidimo da je AUC 0.996 što je izuzetno visok skor. Kriva odmah raste ka gornjem levom uglu što znači da model pri gotovo svakom pragu razlikuje klasu 0 od klase 1 sa minimalnim brojem lažnih alarma.



Slika 13: PR kriva za MFCC model


Kod PR(Precision-Recall) krive vidimo da je AP 0.96 što je odličan rezultat

s obzirom da imamo nebalasiran skup podataka. Vidimo da je veći deo krive precision 1 sve dok se ne dođe do recall 0.8 zatim kreće da opada. To znači da model žrtvuje preciznost kako bi pokrio poslednje pozitivne uzorke. PR kriva je strožija u analizi kvaliteta modela i i dalje je dala veoma dobar rezultat što samo pokazuje da model radi odlično.

3.2 Rezultati LFCC modela

Nakon treniranja CNN modela nad LFCC reprezentacijama izvršena je evaluacija uspešnosti modela na test skupu podataka. Za procenu performansi korišćene su standardne metrike binarne klasifikacije, uključujući accuracy, precision, recall i F1-score, kao i analiza konfuzione matrice, ROC krive i Precision-Recall krive.

Dobijena konfuziona matrica prikazana je na slici 14. Iz matrice se može primetiti da model veoma uspešno prepoznaje negativnu klasu. Od ukupno 15587 negativnih primera samo 53 su pogrešno klasifikovana kao pozitivna klasa. Sa druge strane, model je uspešno prepoznao 391 pozitivan primer, dok je 204 pozitivna uzorka klasifikovao kao negativna klasa.



Slika 14: Konfuziona matrica LFCC modela

Na slici 15 prikazan je detaljan izveštaj klasifikacije modela. Ostvarena ukupna tačnost klasifikacije iznosi približno 98.41%, što ukazuje da model

veoma uspešno razlikuje prisustvo i odsustvo ključne reči.


Precision za pozitivnu klasu iznosi približno 0.88, što znači da velika većina uzoraka koje model označi kao prisustvo ključne reči zaista pripada pozitivnoj klasi. Recall vrednost iznosi približno 0.66, što pokazuje da model uspešno prepoznaje značajan broj pozitivnih primera, ali i dalje propušta određeni deo stvarnih pojavljivanja ključne reči. F1-score pozitivne klase iznosi približno 0.75 i predstavlja kompromis između precision i recall metrike.

Razlika između precision i recall vrednosti ukazuje da je model prilično konzervativan prilikom donošenja odluke o prisustvu ključne reči. Drugim rečima, model radije izbegava lažne aktivacije nego što pokušava da detektuje svaki mogući pozitivan primer. Zbog toga postiže visoku precision vrednost, ali istovremeno propušta deo stvarnih pozitivnih uzoraka. Ovakvo ponašanje je očekivano kod problema detekcije aktivacione reči, gde je često poželjno smanjiti broj pogrešnih aktivacija sistema.

LFCC Accuracy: 0.9841181559757756					
[[15534 53]					
[204 391]]					
	precision	recall	f1-score	support	
0.0	0.99	1.00	0.99	15587	
1.0	0.88	0.66	0.75	595	
accuracy			0.98	16182	
macro avg	0.93	0.83	0.87	16182	
weighted avg	0.98	0.98	0.98	16182	


Slika 15: Izveštaj klasifikacije LFCC modela

Na slici 16 prikazana je ROC (Receiver Operating Characteristic) kriva LFCC modela. Površina ispod ROC krive (AUC) iznosi približno 0.98, što ukazuje na veoma dobru sposobnost modela da razlikuje pozitivne i negativne primere nezavisno od izabranog praga odlučivanja. Kriva se nalazi blizu gornjeg levog ugla grafikona, što predstavlja poželjno ponašanje klasifikatora.



Slika 16: ROC kriva LFCC modela

Na slici 17 prikazana je Precision-Recall kriva LFCC modela. Dobijena Average Precision (AP) vrednost iznosi približno 0.83, što predstavlja veoma dobar rezultat imajući u vidu izraženu neuravnoteženost skupa podataka. Može se primetiti da model zadržava veoma visoku preciznost za manje i srednje vrednosti recall metrike, dok sa povećanjem recall-a dolazi do postepenog opadanja precision vrednosti. To pokazuje da model mora da pravi kompromis između obuhvatanja većeg broja pozitivnih primera i očuvanja visoke preciznosti klasifikacije.




Slika 17: Precision-Recall kriva LFCC modela

Na osnovu dobijenih rezultata može se zaključiti da LFCC model ostvaruje veoma dobre performanse u zadatku detekcije ključne reči. Visoka tačnost klasifikacije, mali broj lažno pozitivnih predikcija i velika površina ispod ROC krive potvrđuju da model uspešno razlikuje prisustvo i odsustvo ključne reči. Istovremeno, recall vrednost pokazuje da postoji prostor za dodatno unapređenje modela kroz optimizaciju hiperparametara, balansiranje podataka ili primenu složenijih arhitektura neuronskih mreža.

3.3 Poređenje MFCC i LFCC pristupa


Cilj našeg projekta je upravo da vidimo kako se ponašaju različiti modeli nastali koršćenjem iste konvolutivne neuronske mreže. Konkretno u našem slučaju radimo poređenje dobijenih rezultata modela nastalih iz MFCC odnosno LFCC reprezentacija audio snimaka.

U nastavku ćemo prikazati zajedničke grafike ROC i PR kriva kod MFCC, odnosno LFCC reprezentacije. Kao dve metode vizuelizacije kvaliteta modela koje najslikovitije i najbliže opisuju koliko je neki model dobar, ROC i PR krive su najbolji način da se uporede dva modela nastala od iste neuronske mreže.



Slika 18: ROC krive MFCC i LFCC modela

Na prethodnoj slici plavom bojom označena je ROC kriva MFCC modela, a narandžastom bojom označena je ROC kriva LFCC modela. Možemo primetiti da je AUC skor za nijansu veći kod MFCC modela u odnosu na LFCC model, kao i da ROC kriva kod MFCC modela brže raste ka gornjem levom uglu. Razlika se pojavljuje u zoni FPR 0.01-0.20. To znači da pri istoj stopi lažnih alarma, MFCC hvata značajno više stvarnih pozitivnih. Razlika je u suštini mala, ali na ogromnim skupovima može biti u stotinama uzoraka razlike.



Slika 19: PR krive MFCC i LFCC modela

Na slici je kao i u prethodnom slučaju plavom bojom označena PR kriva MFCC modela, a narandžastom bojom označena je PR kriva LFCC modela. Možemo primetiti da je AP skor zapravo dosta veći kod MFCC modela u odnosu na LFCC model. PR kriva kod LFCC modela brže opada ka donjem desnom uglu, gde se vidi da kod MFCC precision ostaje 1 sve do 0.8 recall, a kod LFCC kreće pad već od 0.6 recall odnosno LFCC mnogo ranije kreće da žrtvuje preciznost kako bi obuhvatila što više pozitivnih slučajeva.

4 Zaključak

U ovom radu razmatran je problem detekcije aktivacione reči "stop" iz Google Speech Commands skupa podataka korišćenjem konvolucione neuronske mreže, sa fokusom na poređenje dve metode za izdvajanje karakteristika audio signala - MFCC i LFCC reprezentacije audio signala.

Rezultati su pokazali uspešnost i veoma dobre performanse oba pristupa u zadatku binarne klasifikacije, ali je jasno bila izražena razlika u korist MFCC reprezentacije podataka. Razlika u AP vrednosti od gotovo 14% posebno je značajna, s obzirom na to da PR kriva predstavlja strožiji kriterijum evaluacije u uslovima nebalansiranog skupa podataka.

Ključna prednost MFCC reprezentacije leži u korišćenju Mel skale frekvencija, koja modeluje način na koji ljudsko uho percipira zvuk. Zahvaljujući tome MFCC prirodno naglašava frekvencijske opsege najrelevantnije za govor, kao što su niže frekvencije. LFCC, s druge strane, koristi linearnu frekvencijsku skalu u odnosu na Mel skalu i ravnomerno tretira niske i visoke frekvencije čime može izgubiti neke informacije koje su korisne za razlikovanje klasa, što može biti korisno u određenim kontekstima, ali se pokazalo manje efikasnim za zadatak detekcije aktivacione reči iz audio signala.

Najveći izazov u kreiranju dobrog modela nad ovim skupom podataka bila je činjenica da je skup podataka bio izuzetno nebalansiran. To je imalo velikog uticaja na to kako će određen model raditi. Poboljšanje se može dobiti ukoliko se primeni neka metoda balansiranja podataka poput oversamplinga.

Ovo istraživanje potvrđuje da izbor metode za izdvajanje karakteristika audio signala ima veliki uticaj na performanse modela za detekciju aktivacione reči, te da MFCC reprezentacija predstavlja optimalniji izbor za ovakav tip zadatka u poređenju sa LFCC reprezentacijom.

5 Literatura

1. H. Muckenhirn, M. Todisco, X. Wang, N. Evans i S. Marcel, *The ASVspoof 2019 Baseline: LFCC-GMM and CQCC-GMM Anti-Spoofing Systems*, arXiv preprint arXiv:1904.05576, 2019.
2. D. P. Kingma i J. Ba, *Adam: A Method for Stochastic Optimization*, International Conference on Learning Representations (ICLR), 2015.
3. A. Paszke i saradnici, *PyTorch: An Imperative Style, High-Performance Deep Learning Library*, NeurIPS, 2019.
4. F. Pedregosa i saradnici, *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, 12, 2825–2830, 2011.
5. G. Chen, C. Parada i G. Heigold, *Small-Footprint Keyword Spotting Using Deep Neural Networks*, ICASSP, 2014.